

Du geste au modèle :


Construire et classifier les mouvements humains avec l'IA

Nathan SALAZAR, Nicolas PRONOST, Alexandre MEYER
Équipe SAARA

Contexte & motivation

- Humains virtuels dans les applications numériques
- Modèles de représentation et de génération des gestes humains

⇒ **Utilisation de l'apprentissage profond**



Utilité pour l'animation, la VR, ...

Contexte & motivation

Coût et d'échelle

- La motion capture classique est chère : studio, combinaison à marqueurs, matériel dédié
- Estimer le mouvement depuis une simple vidéo RGB monoculaire supprime cette infrastructure

Un domaine en progrès rapide

- Moins d'artefacts (ex : *foot sliding* réduit, mouvements fluides, adaptés à la morphologie, moins de problème de profondeurs)
- Plus rapides et plus robustes, y compris sur vidéos non contrôlées

Données extraites via Motion Capture



Données extraites depuis RGB



Objectif

- Filmer un joueur faire un coup de tennis
- Un premier modèle extrait les mouvements 3D de la personne filmée
- Un deuxième modèle classifie le geste réalisé parmi des catégories de coups

Objectif

- Filmer un joueur faire un coup de tennis
- Un premier modèle extrait les mouvements 3D de la personne filmée
- Un deuxième modèle classifie le geste réalisé parmi des catégories de coups



Revers, coup droit, service, smash ?

Objectif

- Filmer un joueur faire un coup de tennis
- Un premier modèle extrait les mouvements 3D de la personne filmée
- Un deuxième modèle classifie le geste réalisé parmi des catégories de coups

2 approches

- **MediaPipe**

Rapide et léger



- **GVHMR**

Plus précis et complet (SOTA)



<https://github.com/ucacaxm/MotionDatasetAndModel>

Approche rapide: Mediapipe

Utilisation du modèle **BlazePose** de MediaPipe

Sortie

- 33 points 3D du corps
- Coordonnées relatives (x, y, z)
- Une estimation à chaque image

Avantages

- Très rapide, compatible temps réel
- Installation simple

Approche rapide: Mediapipe

Utilisation du modèle **BlazePose** de MediaPipe

Sortie

- 33 points 3D du corps
- Coordonnées relatives (x, y, z)
- Une estimation à chaque image

Avantages

- Très rapide, compatible temps réel
- Installation simple



Inférence via BlazePose

Approche lente mais SOTA: GVHMR

Sortie

- Paramètres SMPL-X
- Coordonnées globales (x, y, z)
- Une estimation pour le mouvement entier

Avantages

- Très précis, estimation globale
- Format très utilisé en recherche (SMPL)
- Robuste sur des vidéos non contrôlées


Approche lente mais SOTA: GVHMR

Sortie

- Paramètres SMPL-X
- Coordonnées globales (x, y, z)
- Une estimation pour le mouvement entier

Avantages

- Très précis, estimation globale
- Format très utilisé en recherche (SMPL)
- Robuste sur des vidéos non contrôlées



Inférence via GVHMR

Données vidéo

MediaPipe ⇒ **THETIS**

- Vidéos face caméra, environnement contrôlé
- Un seul geste par séquence
- 1980 séquences

GVHMR ⇒ **Dataset personnalisé**

- Vidéos *in-the-wild* (YouTube)
- 645 séquences
- Gestes variés : 210 coups droits, 181 revers, 39 services
- Une séquence peut contenir plusieurs gestes ou aucun

Données vidéo

MediaPipe ⇒ **THETIS**

- Vidéos face caméra, environnement contrôlé
- Un seul geste par séquence
- 1980 séquences

GVHMR ⇒ **Dataset personnalisé**

- Vidéos *in-the-wild* (YouTube)
- 645 séquences
- Gestes variés : 210 coups droits, 181 revers, 39 services
- Une séquence peut contenir plusieurs gestes ou aucun



Exemple issu de THETIS




*Exemple issu de notre dataset
(Vidéos YouTube libres de droits)*

Pipeline général


L'idée générale est la même entre les 2 méthodes :



Vidéo




GVHMR



Inférence: Récolte des données à partir des vidéos

Extraction features



Classification

Output

Features

Représentation de nos mouvements pour l'entraînement

MediaPipe


- Extraction des 33 points 3D du corps
- Ajout de la vitesse de chaque point pour prendre en compte le mouvement

⇒ $(33 \text{ positions} + 33 \text{ vitesses}) * 3 \text{ dimensions} = 198 \text{ valeurs par frame}$


GVHMR

- Extraction des rotations 3D des 22 articulations et de la translation globale, de la morphologie du corps
- Utilisation des rotations des articulations et de la translation globale
- Conversion des rotations en représentation 6D, plus adaptée pour l'apprentissage

⇒ $22 \text{ rotations} * 6 + 3 \text{ translations} = 135 \text{ valeurs par frame}$



Skeleton BlazePose (Mediapipe)



Skeleton SMPL (GVHMR)

Comparaison

Mediapipe	GVHMR
Rapide mais imprécis 33 points en positions 3D <u>Positions + vitesses</u> Dataset THETIS	Lent mais très précis Paramètres SMPL (22 points 3D avec leurs rotations et translation globale) <u>Rotations 6D + translation</u> Dataset créé avec Youtube puisque GVHMR le permet

En bref

- Mediapipe : simplicité et légèreté
- GVHMR : qualité, robustesse, flexibilité

Concepts

Normalisation

- Mise à l'échelle des données et recentrage à l'origine (0,0,0)
- Réduit l'impact de la position et de la morphologie

⇒ Le modèle se concentre uniquement sur le mouvement

Augmentation des données

- Génération de nouvelles données à partir des poses existantes
- Rotation autour de l'axe vertical (MediaPipe)

⇒ Rend le modèle invariant à l'orientation de la caméra

Concepts

Normalisation


- Mise à l'échelle des données et recentrage à l'origine (0,0,0)
- Réduit l'impact de la position et de la morphologie

⇒ Le modèle se concentre uniquement sur le mouvement

Augmentation des données

- Génération de nouvelles données à partir des poses existantes
- Rotation autour de l'axe vertical (MediaPipe)

⇒ Rend le modèle invariant à l'orientation de la caméra




*Exemple d'augmentation :
même mouvement avec des rotations
autour de l'axe Y différentes*

Architectures

MLP (Multi-Layer Perceptron)


- Les caractéristiques de toute la séquence sont **agrégées en un seul vecteur**
- Simple, rapide et peu coûteux en calcul
- Ne prend pas en compte les relations spatio-temporelles



MLP (Multi Layer Perceptron)

CNN 1D (Convolution 1D)

- Applique des **filtres sur la dimension temporelle** de la séquence
- Détecte des motifs locaux (gestes, transitions, répétitions) et conserve l'information temporelle
- Moins bon que des modèles séquentiels



Convolution 1D

Entraînement

- **AdamW** : Optimisation stable + régularisation (weight decay)
- **BCE with Logits** : adaptée à une classification **multi-label**, où plusieurs types de gestes peuvent être présents simultanément

Démo

Une interface dans les dernières cellules permet de tester le modèle avec la webcam de votre ordinateur



- Autoriser l'accès à la caméra dans le navigateur
- L'enregistrement démarre automatiquement pendant 3 secondes
- Le modèle analyse ensuite la vidéo et classifie le geste réalisé

⇒ **Permet de tester le modèle en conditions réelles, directement avec sa propre caméra**

Références

- **MediaPipe: A Framework for Perceiving and Processing Reality**
Lugaresi et al., CVPR Workshops 2019
- **GVHMR: World-Grounded Human Motion Recovery via Gravity-View Coordinates**
Shen et al., SIGGRAPH Asia 2024
- **SMPL: A Skinned Multi-Person Linear Model**
Loper et al., SIGGRAPH Asia 2015
- **On the Continuity of Rotation Representations in Neural Networks (6D rotations)**
Zhou et al., CVPR 2019
- **THETIS: Three-dimensional Tennis Shots Human Action Dataset**
Gourgari et al., CVPR Workshops 2013
- **XmoPipe: A Pipeline for Large-Scale In-the-Wild Human Motion Dataset Construction**
N. Salazar, E. Dellandréa, M. Lefort, A. Meyer, CASAXR 2026

Références (GVHMR)




Gravity-View method

- (1) Naturally considers gravity.
- (2) Uniquely defined for each image.
- (3) Avoids error accumulation along gravity direction for consecutive images.


GVHMR pipeline

GVHMR preprocesses a monocular video by extracting human and camera features, fuses them into per-frame tokens processed by a transformer, predicts SMPL parameters and motion cues, then reconstructs the human's global trajectory in the world coordinate system.

Références (Mediapipe)



*BlazePose's Architecture: Tracking network architecture:
regression with heatmap supervision*



BlazePose's human pose estimation pipeline overview