

Du geste au modèle :

Construire et classifier les mouvements humains avec l'IA



Objectif

- Filmer un joueur faire un coup de tennis
- Un premier modèle extrait les mouvements 3D de la personne filmée
- Un deuxième modèle classifie le geste réalisé parmi des catégories de coups

Objectif

- Filmer un joueur faire un coup de tennis
- Un premier modèle extrait les mouvements 3D de la personne filmée
- Un deuxième modèle classifie le geste réalisé parmi des catégories de coups



Revers, coup droit, service, smash ?

Objectif

- Filmer un joueur faire un coup de tennis
- Un premier modèle extrait les mouvements 3D de la personne filmée
- Un deuxième modèle classifie le geste réalisé parmi des catégories de coups

2 approches

- **MediaPipe**

Rapide et léger



- **GVHMR**

Plus précis et complet (SOTA)



Approche rapide: Mediapipe

Utilisation du modèle **BlazePose** de MediaPipe

Sortie

- 33 points 3D du corps
- Coordonnées relatives (x, y, z)
- Une estimation à chaque image

Avantages

- Très rapide, compatible temps réel
- Installation simple

Approche rapide: Mediapipe

Utilisation du modèle **BlazePose** de MediaPipe

Sortie

- 33 points 3D du corps
- Coordonnées relatives (x, y, z)
- Une estimation à chaque image

Avantages

- Très rapide, compatible temps réel
- Installation simple



Inférence via BlazePose

Approche lente mais SOTA: GVHMR

Sortie

- 22 points 3D du corps, paramètres SMPL
- Coordonnées globales (x, y, z)
- Une estimation pour le mouvement entier

Avantages

- Très précis, estimation globale
- Format très utilisé en recherche (SMPL)
- Robuste sur des vidéos non contrôlées


Approche lente mais SOTA: GVHMR

Sortie

- 22 points 3D du corps, paramètres SMPL
- Coordonnées globales (x, y, z)
- Une estimation pour le mouvement entier

Avantages

- Très précis, estimation globale
- Format très utilisé en recherche (SMPL)
- Robuste sur des vidéos non contrôlées



Inférence via GVHMR

Données vidéo

MediaPipe ⇒ **THETIS**

- Vidéos face caméra, environnement contrôlé
- Un seul geste par séquence
- 1980 séquences

GVHMR ⇒ **Dataset personnalisé**

- Vidéos *in-the-wild* (YouTube)
- 645 séquences
- Gestes variés : 210 coups droits, 181 revers, 39 services
- Une séquence peut contenir plusieurs gestes ou aucun

Données vidéo

MediaPipe ⇒ **THETIS**

- Vidéos face caméra, environnement contrôlé
- Un seul geste par séquence
- 1980 séquences

GVHMR ⇒ **Dataset personnalisé**

- Vidéos *in-the-wild* (YouTube)
- 645 séquences
- Gestes variés : 210 coups droits, 181 revers, 39 services
- Une séquence peut contenir plusieurs gestes ou aucun



Exemple issu de THETIS





*Exemple issu de notre dataset
(Vidéos YouTube libres de droits)*

Pipeline général


L'idée générale est la même entre les 2 méthodes :



Vidéo




GVHMR



Inférence: Récolte des données à partir des vidéos

Extraction features



Classification

Output

Features

Représentation de nos mouvements pour l'entraînement

MediaPipe


- Extraction des 33 points 3D du corps
- Ajout de la vitesse de chaque point pour prendre en compte le mouvement

⇒ $(33 \text{ positions} + 33 \text{ vitesses}) * 3 \text{ dimensions} = 198 \text{ valeurs par frame}$


GVHMR

- Extraction des rotations 3D des 22 articulations et de la translation globale, de la morphologie du corps
- Utilisation des rotations des articulations et de la translation globale
- Conversion des rotations en représentation 6D, plus adaptée pour l'apprentissage

⇒ $22 \text{ rotations} * 6 + 3 \text{ translations} = 135 \text{ valeurs par frame}$



Skeleton BlazePose (Mediapipe)



Skeleton SMPL (GVHMR)

Comparaison

Mediapipe	GVHMR
Rapide mais imprécis 33 points en positions 3D <u>Positions + vitesses</u> Dataset THETIS	Lent mais très précis Paramètres SMPL (22 points 3D avec leurs rotations et translation globale) <u>Rotations 6D + translation</u> Dataset créé avec Youtube puisque GVHMR le permet

En bref

- Mediapipe : simplicité et légèreté
- GVHMR : qualité, robustesse, flexibilité

Concepts

Normalisation

- Mise à l'échelle des données et recentrage à l'origine (0,0,0)
- Réduit l'impact de la position et de la morphologie

⇒ Le modèle se concentre uniquement sur le mouvement

Augmentation des données

- Génération de nouvelles données à partir des poses existantes
- Rotation autour de l'axe vertical (MediaPipe)

⇒ Rend le modèle invariant à l'orientation de la caméra

Concepts

Normalisation


- Mise à l'échelle des données et recentrage à l'origine (0,0,0)
- Réduit l'impact de la position et de la morphologie

⇒ Le modèle se concentre uniquement sur le mouvement

Augmentation des données

- Génération de nouvelles données à partir des poses existantes
- Rotation autour de l'axe vertical (MediaPipe)

⇒ Rend le modèle invariant à l'orientation de la caméra



*Exemple d'augmentation :
même mouvement avec des
rotations différentes*

Architectures

MLP (Multi-Layer Perceptron)


- Les caractéristiques de toute la séquence sont **agrégées en un seul vecteur**
- Simple, rapide et peu coûteux en calcul
- Ne prend pas en compte les relations spatio-temporelles

CNN 1D (Convolution 1D)


- Applique des **filtres sur la dimension temporelle** de la séquence
- Détecte des motifs locaux (gestes, transitions, répétitions) et conserve l'information temporelle
- Moins bon que des modèles séquentiels

Entraînement

- **AdamW** : Optimisation stable + régularisation (weight decay)
- **BCE with Logits** : adaptée à une classification **multi-label**, où plusieurs types de gestes peuvent être présents simultanément



MLP (Multi Layer Perceptron)



Convolution 1D

Démo

Une interface dans les dernières cellules permet de tester le modèle avec la webcam de votre ordinateur



- Autoriser l'accès à la caméra dans le navigateur
- L'enregistrement démarre automatiquement pendant 3 secondes
- Le modèle analyse ensuite la vidéo et classifie le geste réalisé

⇒ **Permet de tester le modèle en conditions réelles, directement avec sa propre caméra**

Références

- **MediaPipe: A Framework for Perceiving and Processing Reality**
Lugaresi et al., CVPR Workshops 2019
- **GVHMR: World-Grounded Human Motion Recovery via Gravity-View Coordinates**
Shen et al., SIGGRAPH Asia 2024
- **SMPL: A Skinned Multi-Person Linear Model**
Loper et al., SIGGRAPH Asia 2015
- **On the Continuity of Rotation Representations in Neural Networks (6D rotations)**
Zhou et al., CVPR 2019
- **THETIS: Three-dimensional Tennis Shots Human Action Dataset**
Gourgari et al., CVPR Workshops 2013

Références (GVHMR)




Gravity-View method

- (1) Naturally considers gravity.
- (2) Uniquely defined for each image.
- (3) Avoids error accumulation along gravity direction for consecutive images.


GVHMR pipeline

GVHMR preprocesses a monocular video by extracting human and camera features, fuses them into per-frame tokens processed by a transformer, predicts SMPL parameters and motion cues, then reconstructs the human's global trajectory in the world coordinate system.

Références (Mediapipe)



BlazePose's Architecture: Tracking network architecture:
regression with heatmap supervision



BlazePose's human pose estimation pipeline overview